

# 【手撕LLM-KVCache】显存刺客的前世今生--文末含代码



小冬瓜AIGC

原创课程 公众号: 手撕LLM

来自专栏 · 手撕LLM >

289 人赞同了该文章 >

我是小冬瓜AIGC，原创超长文知识分享，原创课程已帮助多名同学速成上岸LLM赛道：[手撕LLM+RLHF](#)  
研究方向：LLM、RLHF、Safety、Alignment

本文摘自[高效Attention]系列：[【手撕LLM-KVCache】显存刺客的前世今生](#)

阅读本文前推荐阅览：[小冬瓜AIGC：【手撕LLM-Generation】Top-K+重复性惩罚](#)

## 前言

### 什么是KV-Cache?

KV-Cache 是一种加速推理的技术, 现代的LLM使用, 包括 LLaMA

KV-Cache 在长文本输入的情况下, 占用的显存线性随句长增长, 此时需要做 cache 优化

可以说系统掌握KV-Cache是做LLM推理加速的基础, 另一条线路是纯GPU算法优化如[FlashAttention](#)

阅读完本文可以掌握:

- LLM 推理中的 KV-Cache 作用、原理、流程
- KV-Cache 的显存占用量分析
- KV-Cache 的优化手段
- 手撕 KV-Cache
- 现代 LLM 架构, 不同的 KV-Cache 优化实现手段

## 1. Generate时的Next Token推理

```
1 # 无KV-Cache
2 idx = torch.randn([1,10])
3 for i in range(max_length):
4     logist = model(idx)
5     next_idx = softmax(argmax(logist))
6     idx = cat(idx, next_idx)
```

```
1 # 有KV-Cache
2 idx = torch.randn([1,10])
3 for i in range(max_length):
4     logist = model(idx)
5     next_idx = softmax(argmax(logist))
6     idx = next_idx
```

知乎 @小冬瓜AIGC

### 1.1 无KV-Cache生成代码

- 无 KV-Cache 推理

```
import torch
import torch.nn.functional as F
from transformers import LlamaModel, LlamaConfig, LlamaForCausalLM

# 加载模型
```

```

config = LlamaConfig(vocab_size = 100,
                    hidden_size = 256,
                    intermediate_size = 512,
                    num_hidden_layers = 2,
                    num_attention_heads = 4,
                    num_key_value_heads = 4,
                    )
model = LlamaForCausalLM(config)

# 创建数据、不使用tokenizer
X = torch.randint(0, 100, (1,10))
print(X.shape)

#
idx={}
idx['input_ids'] = X
for i in range(4):
    print(f"\nGeneration第{i}个时的输入{idx['input_ids'].shape}: ")
    print(f"Generation第{i}个时的输入{idx['input_ids']}: ")
    output = model(**idx)
    logits = output['logits'][:, -1, :]
    idx_next = torch.argmax(logits, dim=-1)[0]

    idx['input_ids'] = torch.cat((idx['input_ids'], idx_next.unsqueeze(0).unsqueeze(1)), dim=-1)

```

## 输出结果

```

torch.Size([1, 10])

Generation第0个时的输入torch.Size([1, 10]):
Generation第0个时的输入tensor([[48,  8, 96,  3,  1,  3, 65, 85, 18, 25]]):

Generation第1个时的输入torch.Size([1, 11]):
Generation第1个时的输入tensor([[48,  8, 96,  3,  1,  3, 65, 85, 18, 25,  1]]):

Generation第2个时的输入torch.Size([1, 12]):
Generation第2个时的输入tensor([[48,  8, 96,  3,  1,  3, 65, 85, 18, 25,  1, 66]]):

Generation第3个时的输入torch.Size([1, 13]):
Generation第3个时的输入tensor([[48,  8, 96,  3,  1,  3, 65, 85, 18, 25,  1, 66,  3]]):

```

## 1.2 有KV-Cache生成代码

- 在推理时，计算  $Q_i @ K^T$  形式的 Attention，如下图
- $Q_i$  对应预测  $Token_{i+1}$

```

# this code generate With KV Cache
i = 0
T = idx.size(0)
T_new = T+max_new_tokens
empty = torch.empty(T_new, dtype=dtype, device=device)
empty[:T] = idx
idx = empty
input_pos = torch.arange(0, T, device=device)
max_new_tokens = 10
for _ in range(max_new_tokens):
    x = idx.index_select(0, input_pos).view(1, -1)
    print(f"input_t{i}: ", x.int())
    i += 1
# forward

```

```

logits = model(x, max_seq_length, input_pos)
probs = torch.nn.functional.softmax(logits, dim=-1)
idx_next = torch.multinomial(probs, num_samples=1).to(dtype=dtype)
# advance
input_pos = input_pos[-1:] + 1
# concatenate the new generation
idx = idx.index_copy(0, input_pos, idx_next)

return idx

```

## 结果

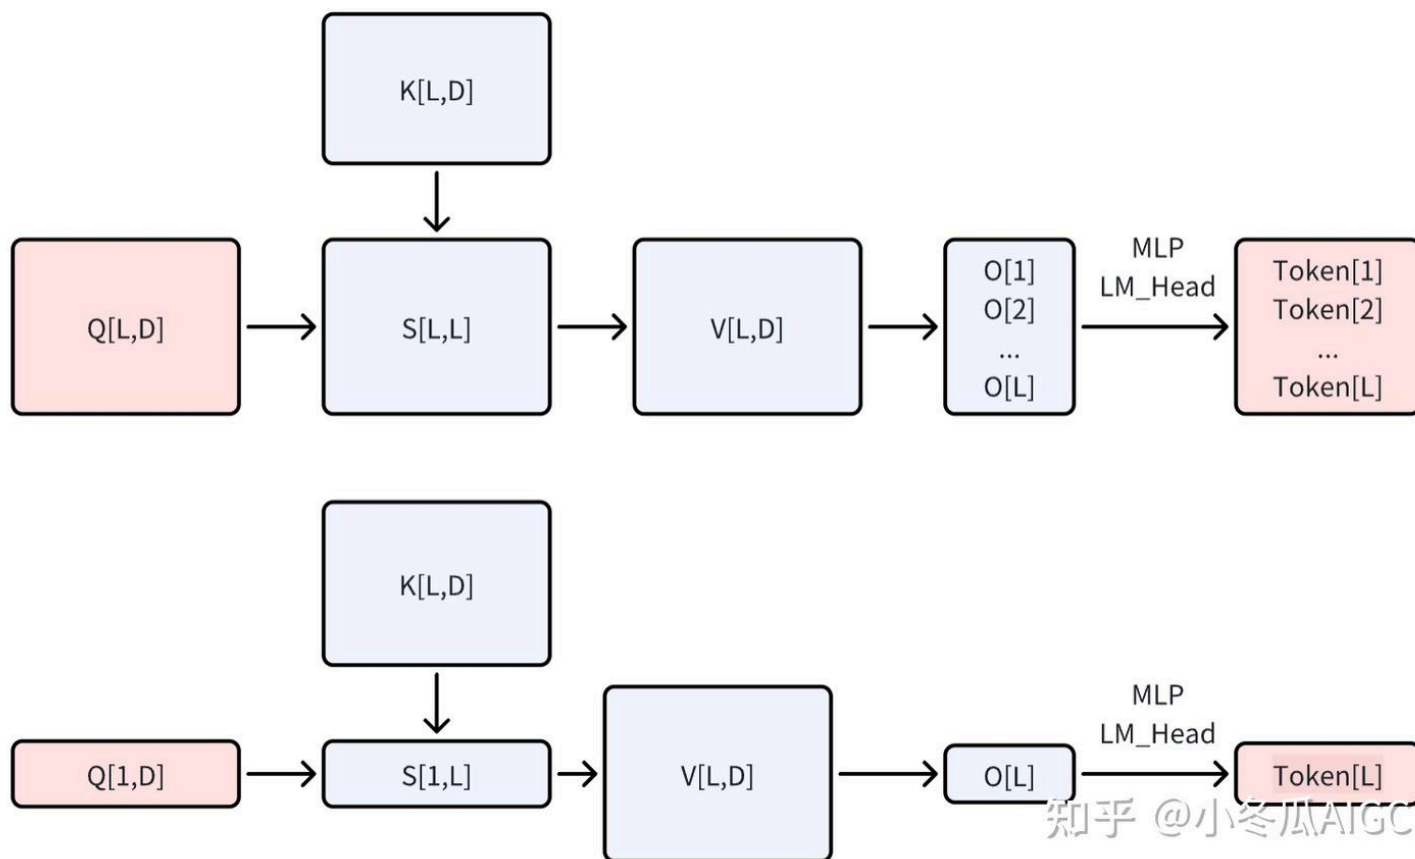
```

input_t0: tensor([[ 1,  3, 13,  9, 20,  4,  3,  9,  5]], dtype=torch.int32)
input_t1: tensor([[3]], dtype=torch.int32)
input_t2: tensor([[8]], dtype=torch.int32)
input_t3: tensor([[4]], dtype=torch.int32)
input_t4: tensor([[3]], dtype=torch.int32)
input_t5: tensor([[6]], dtype=torch.int32)
input_t6: tensor([[13]], dtype=torch.int32)
input_t7: tensor([[6]], dtype=torch.int32)
input_t8: tensor([[15]], dtype=torch.int32)
input_t9: tensor([[23]], dtype=torch.int32)

```

## 2. LLM 训练和推理图解

- 训练时, QKV 满维度算 Attention 得出所有的 `next_token`
- 推理时, 要预测下个 token 只需要当前最尾的一个 `q`
- 我们可以得出一个结论, `Q[-1], K[:, V[:]` 就可以计算 `next_token`

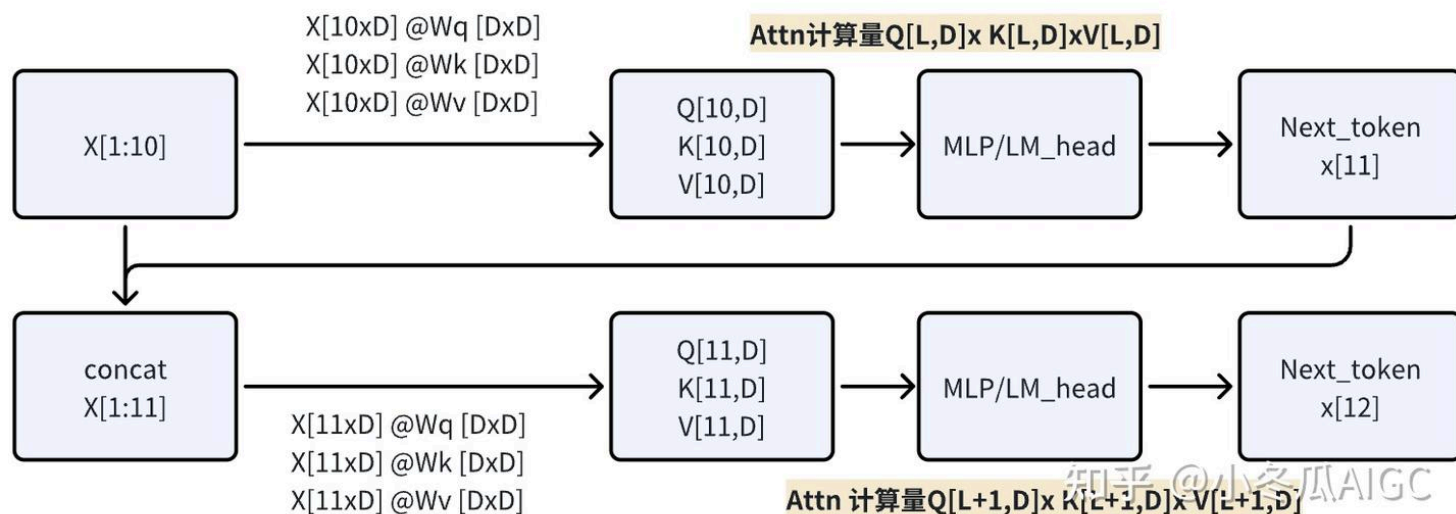


## 3. KV-Cache流程

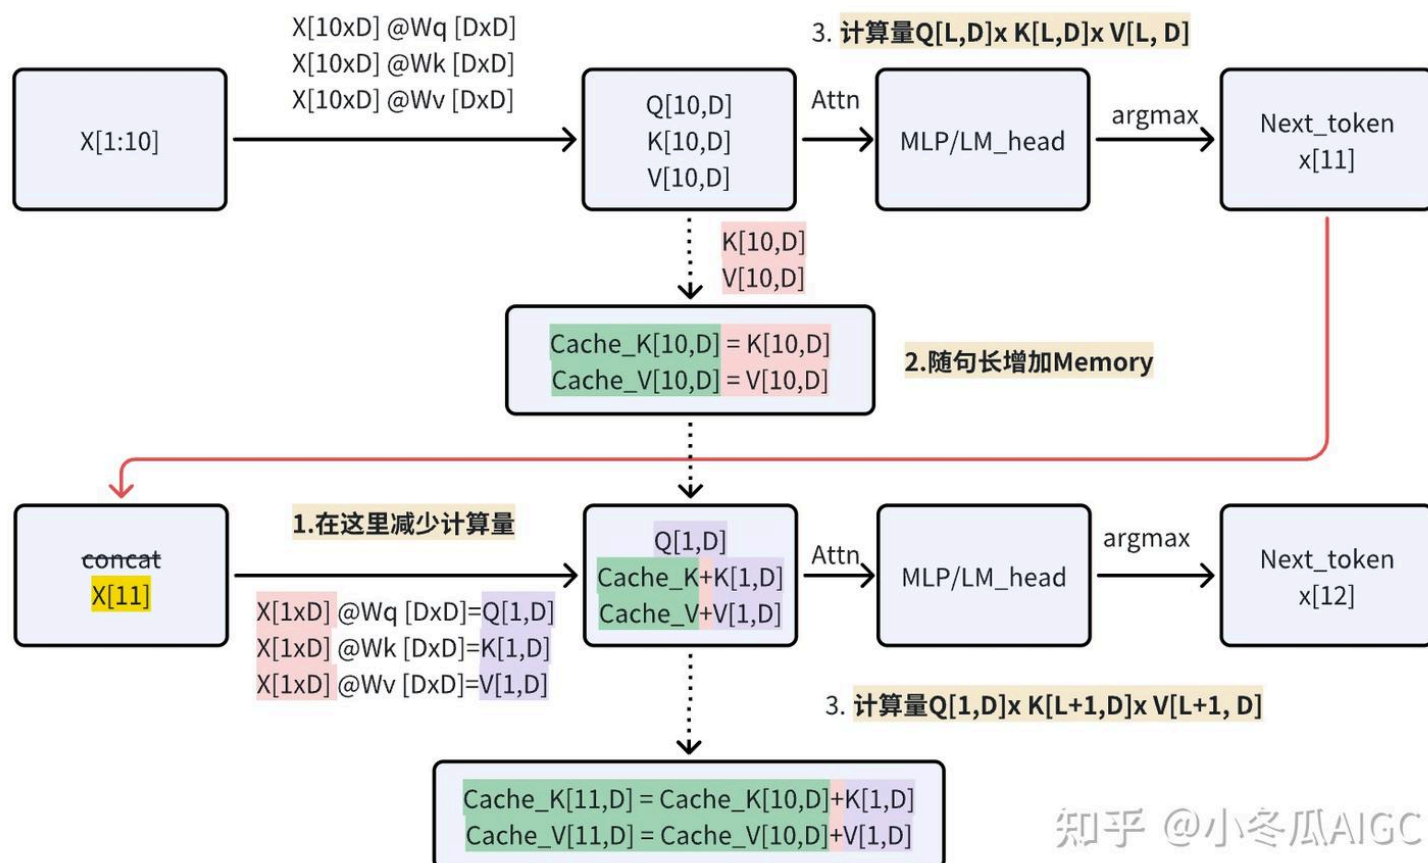
- Without KV-Cache 每次需要计算全  $W_q(X), W_k(X), W_v(X)$ , 每次需要计算全量 Attn

- With KV-Cache , 第一步计算完整 Attn , 将 KV 保存成 KV\_cache
- With KV-Cache , 第二步, 取第一步的 Next Token 计算 QKV , 将 [KV\_cache, KV] 联合, 计算出 QKV
- KV-Cache 每个循环累增, memory 量:  $2 \times (N_{\text{层}} \times L_{\text{长度}} \times D_{\text{维度}})$

## Without KV Cache



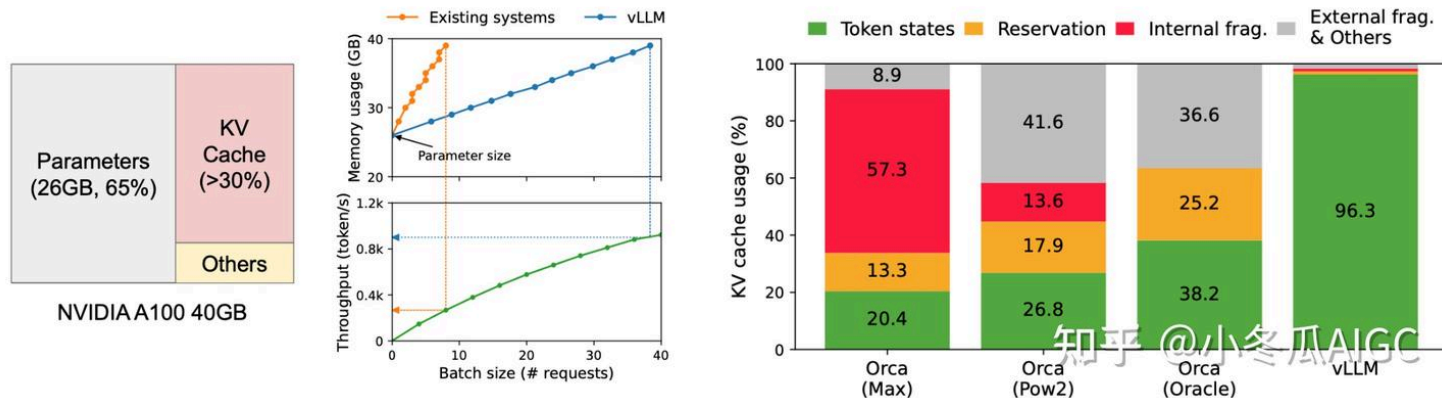
## With KV Cache




## 4. KV-Cache占用分析

- KV-Cache 计算量
  - $2 \times L \times \text{batch\_size} \times [d \times n_{\text{kv\_heads}}] \times \text{Layers} \times k\text{-bits}$
- Existing System Memory中 KV cache >30%占用
- vLLM\* 在40GB能跑30+个 batchsize , 800+ token/s 输出, 相较baseline <10 batchsize , 300+token/s 输出

- 现 GPU KV Cache 中有效存储率低



这里可以看出在连续的存储空间里有大量的 KV-Cache 存储碎片



关于 KV-Cache 的计算量分析，进一步阅读参考这篇博文[Transformer Inference Arithmetic](#)

## 5. KV Cache推理优化

根据公式总结有四类方式

- $2 \times \text{Length} \times \text{batch\_size} \times [d \times n\_kv\_heads] \times \text{Layers} \times k\text{-bits} \times \text{内存模型}$

1.  $n\_kv\_heads$  : MQA / GQA 通过减少KV的头数减少显存占用
2. Length : 通过减少长度 L, 以减少 KV 显存占用, 如使用循环队列管理窗口 KV
3. KV-Cache 的管理: 从 OS (操作系统)的内存管理角度, 减少碎片, 如Paged Attention
4. K-bits : 从量化角度减少 KV cache 的宽度, 如使用 LLM-QAT<sup>+</sup> 进行量化

### 5.1 减少头数 MQA/GQA

- 一种手段是减少KV heads的数量, 如果以 MQA(Multi-Query-Attention) 来说, KV head 8->1 之间节省7倍存储量
- 对于 GQA(Grouped-Query Attention) 来说, 平衡精度将KV head 8 -> N,  $1 < N < 8$ 之间trading off精度和速度
- $2 \times L \times \text{batch\_size} \times D[d \times n\_kv\_heads] \times \text{Layers} \times k\text{-bits}$




Figure 2: Overview of grouped-query method. Multi-head attention has H query, key, and value heads. Multi-query attention shares single key and value heads across all query heads. Grouped-query attention instead shares single key and value heads for each group of query heads, interpolating between multi-head and multi-query attention.

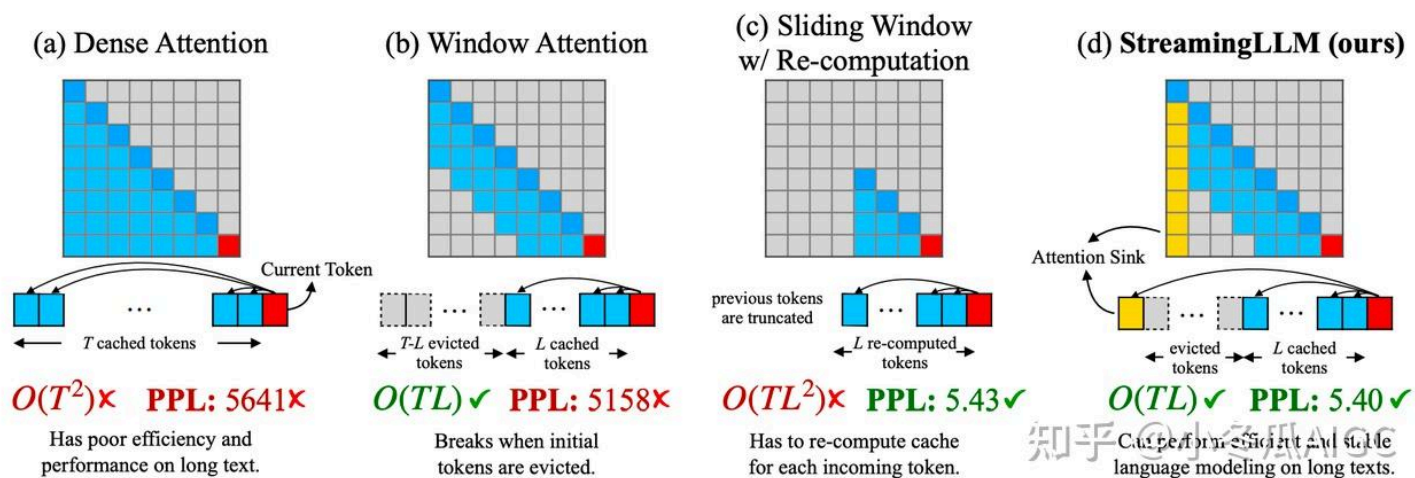
看下 LLaMA 的Cache存储实现, 提前开辟cache的存储空间

- KV 有单独的头数 `n_kv_heads`

```
# llama/llama/model.py
class Attention(nn.Module):
    self.wq = ColumnParallelLinear(
        args.dim,
        args.n_heads * self.head_dim,
    )
    self.wk = ColumnParallelLinear(
        args.dim,
        self.n_kv_heads * self.head_dim, # 与Q的头数不一样
    )
    self.wv = ColumnParallelLinear(
        args.dim,
        self.n_kv_heads * self.head_dim,
    )
    self.cache_k = torch.zeros(
        (
            args.max_batch_size,
            args.max_seq_len,
            self.n_local_kv_heads,
            self.head_dim,
        )
    ).cuda()
    self.cache_v = torch.zeros(
        (
            args.max_batch_size,
            args.max_seq_len,
            self.n_local_kv_heads,
            self.head_dim,
        )
    ).cuda()
```

## 5.2 减少Length长度

- 减少 KV-Cache 的长度, base窗口: Mistral-7B, StreamingLLM, LongLoRA



以下是 Mistral 里采用循环队列

- 将 Cache 长度固定在 sliding-window 长度, 借助 RollingBuffer, 不需要频繁“移位”

```
# mistral-src/mistral/cache.py
# ...
```



```

class RotatingBufferCache:
    def __init__(self, n_layers: int, max_batch_size: int, sliding_window: int, n_kv_heads: int, head_dim: int):

        self.sliding_window = sliding_window
        self.n_kv_heads = n_kv_heads
        self.head_dim = head_dim

        self.cache_k = torch.empty((
            n_layers,
            max_batch_size,
            sliding_window, # 窗口大小的cache
            n_kv_heads,
            head_dim
        ))
        self.cache_v = torch.empty((
            n_layers,
            max_batch_size,
            sliding_window,
            n_kv_heads,
            head_dim
        ))
        # holds the valid length for each batch element in the cache
        self.kv_seqlens = None

```

- 另外 StreamingLLM 采用 torch.tensor split/cat 操作实现

```

# streaming-llm/streaming-llm/kv_cache.py
class StartRecentKVCache:
    ...
    def __call__(self, past_key_values): # 实现sink kv cache
        ...
    def evict_for_space(self, past_key_values, num_coming):
        ...
    def evict_range(self, past_key_values, start, end):
        ...

```

- 在 lit-LLama 中采用"rolling"算子管理 cache 的更新


```

# lit-llama/lit_llama/model.py
if kv_cache is not None:
    cache_k, cache_v = kv_cache
    # check if reached token limit
    if input_pos[-1] >= max_seq_length:
        input_pos = torch.tensor(max_seq_length - 1, device=input_pos.device)
        # shift 1 position to the left
        cache_k = torch.roll(cache_k, -1, dims=2)
        cache_v = torch.roll(cache_v, -1, dims=2)
    k = cache_k.index_copy(2, input_pos, k)
    v = cache_v.index_copy(2, input_pos, v)
    kv_cache = k, v

```

## 5.3 KV-Cache的管理，减少碎片

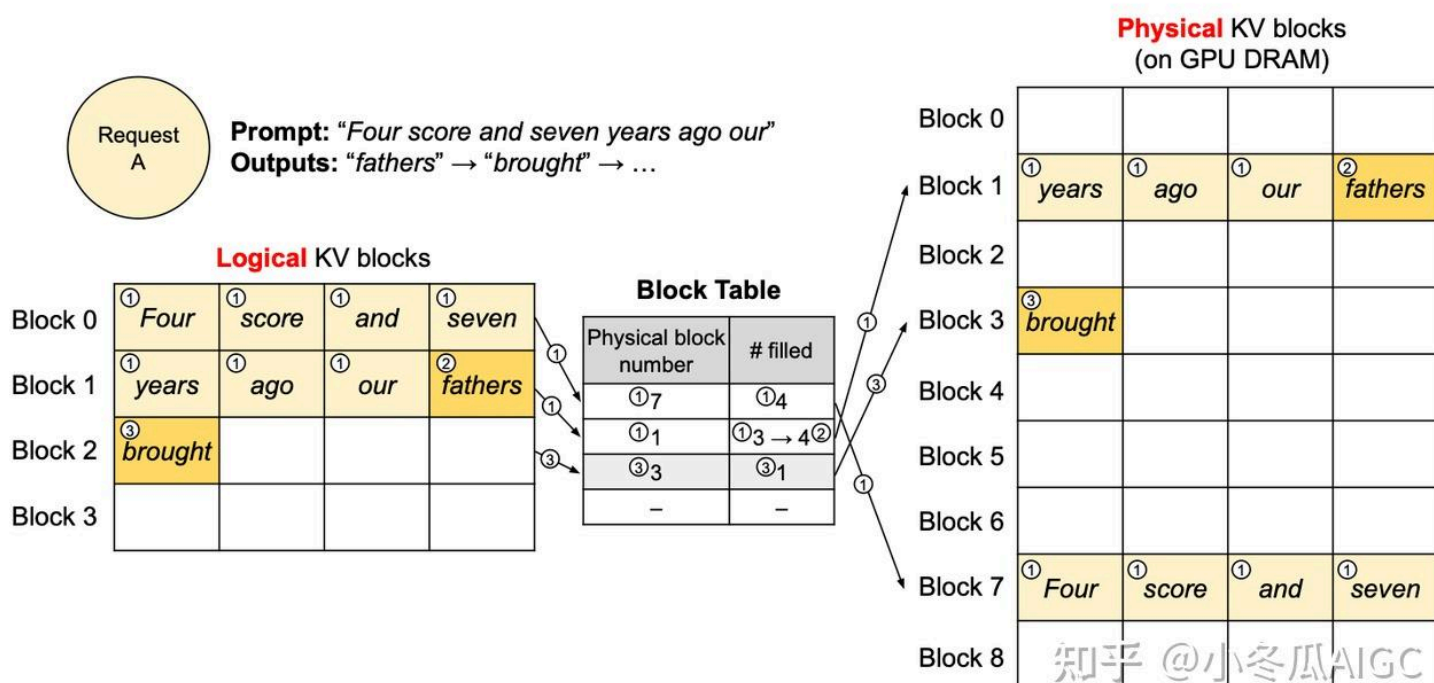
- 优化 KV-Cache 存储模型：PagedAttention
- 对于以下连续存储模型，如果将 Page Length 改成4
- PagedAttention 不是去改变 Attention 的计算，而是改变 KV-cache 的存取方式



Page1	Four	Score	and	Seven
Page2	years	ago	our	
Page3	you	only	live	
Page4				

1. 当完成分页后，消除External Fragmentation
2. 原来的2038+507的内部碎片，现在为1+1
3. 每个Page可以分散的存储在memory中
4. 而page内部的数据存储是连续的

知乎 @小冬瓜AIGC



vLLM 构建了 CacheEngine 先申请一块大的连续 GPU 存储，再自己统一做内存管理

```
# vllm/worker/cache_engine.py
# ...
class CacheEngine:
    def __init__(
        self,
        cache_config: CacheConfig,
        model_config: ModelConfig,
        parallel_config: ParallelConfig,
    ) -> None:
        # ...
        # Initialize the cache.
        self.gpu_cache = self.allocate_gpu_cache()
        self.cpu_cache = self.allocate_cpu_cache()
        # ...
```



## 5.4 减少bits数，量化模型

- LLM-QAT 在量化训练过程，将 KV-Cache 也做 Quantization
- 在部署时 KV-Cache 如果是 16bit，量化成 4bit 的话，显存直接减少4倍

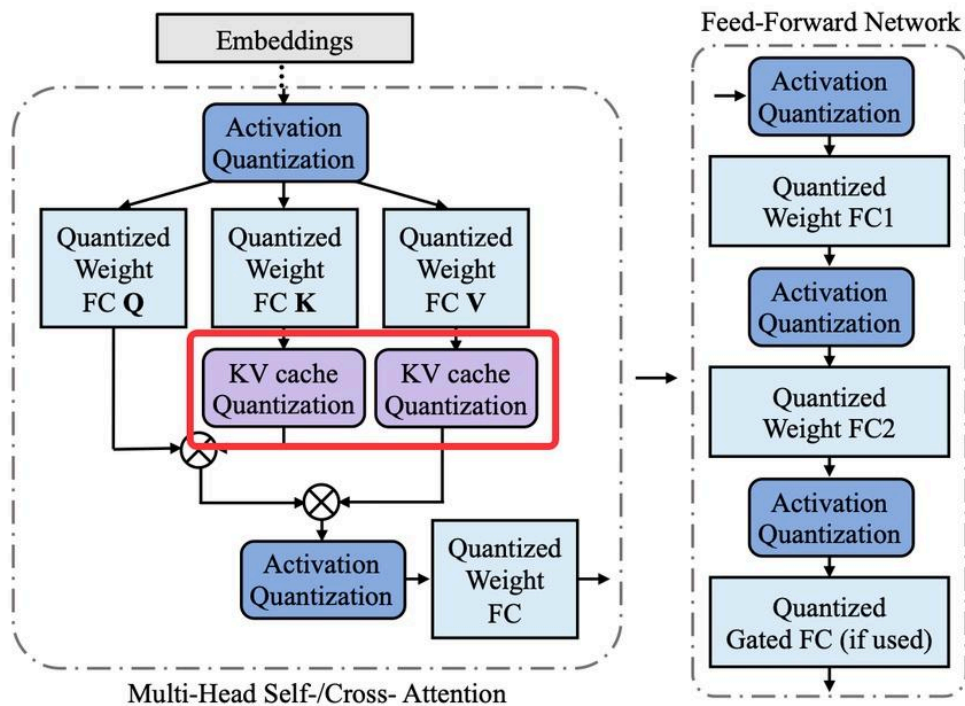


Figure 2: Overview of the quantized transformer in LLM-QAT. We quantize all the weights and input activations in fully-connected linear layers. The KV cache is also quantized if specified.

## 6 手撕KV-Cache

参照该讲解 [【手撕LLM-KVCache】显存刺客的前世今生](#)

手撕 KV-Cache 的推理过程, 可以直接.py或jupyter运行

- 该代码实现一个从 embedding -> attention -> lm\_head 网络
- 该网络带 KV-Cache
- generation 可debug KV-Cache shape

```
# author: xiaodongguaAIGC
# KV-Cache + Generation + decoder

import torch
import torch.nn.functional as F
from transformers import LlamaModel, LlamaConfig, LlamaForCausalLM

D = 128 # single-head-dim
V = 64 # vocab_size

class xiaodonggua_kv_cache(torch.nn.Module):
    def __init__(self, D, V):
        super().__init__()
        self.D = D
        self.V = V
        self.Embedding = torch.nn.Embedding(V, D)
        self.Wq = torch.nn.Linear(D, D)
        self.Wk = torch.nn.Linear(D, D)
```

```

self.Wv = torch.nn.Linear(D,D)
self.lm_head = torch.nn.Linear(D,V) # LM_head
self.cache_K = self.cache_V = None # initial

def forward(self,X):
    X = self.Embedding(X)
    Q,K,V = self.Wq(X),self.Wk(X),self.Wv(X)
    print("input_Q:", Q.shape)
    print("input_K:", K.shape)
    print("input_V:", V.shape)

    # Easy KV_Cache
    if self.cache_K == None:
        self.cache_K = K
        self.cache_V = V
    else:
        self.cache_K = torch.cat((self.cache_K, K), dim = 1)
        self.cache_V = torch.cat((self.cache_V, V), dim = 1)
        K = self.cache_K
        V = self.cache_V

    print("cache_K:", self.cache_K.shape)
    print("cache_V:", self.cache_K.shape)

    # ignore proj/MLP/scaled/mask/multi-head when calculate Attention
    attn =Q@K.transpose(1,2)@V

    # output
    output=self.lm_head(attn)
    return output

model = xiaodonggua_kv_cache(D,V)

# 创建数据、不使用tokenizer
X = torch.randint(0, 64, (1,10))
print(X.shape)

for i in range(4):
    print(f"\nGeneration {i} step input_shape: {X.shape}: ")
    output = model.forward(X)
    print(output.shape)
    next_token = torch.argmax(F.softmax(output, dim = -1),-1)[:,-1]
    print(next_token.shape)
    X = next_token.unsqueeze(0)

```

结果为

```

torch.Size([1, 10])

Generation 0 step input_shape: torch.Size([1, 10]):
input_Q: torch.Size([1, 10, 128])
input_K: torch.Size([1, 10, 128])
input_V: torch.Size([1, 10, 128])
cache_K: torch.Size([1, 10, 128])
cache_V: torch.Size([1, 10, 128])
torch.Size([1, 10, 64])
torch.Size([1])

Generation 1 step input_shape: torch.Size([1, 1]):
input_Q: torch.Size([1, 1, 128])
input_K: torch.Size([1, 1, 128])
input_V: torch.Size([1, 1, 128])

```

```
cache_K: torch.Size([1, 11, 128])
cache_V: torch.Size([1, 11, 128])
torch.Size([1, 1, 64])
torch.Size([1])
```

```
Generation 2 step input_shape: torch.Size([1, 1]):
input_Q: torch.Size([1, 1, 128])
input_K: torch.Size([1, 1, 128])
input_V: torch.Size([1, 1, 128])
cache_K: torch.Size([1, 12, 128])
cache_V: torch.Size([1, 12, 128])
torch.Size([1, 1, 64])
torch.Size([1])
```

```
Generation 3 step input_shape: torch.Size([1, 1]):
input_Q: torch.Size([1, 1, 128])
input_K: torch.Size([1, 1, 128])
input_V: torch.Size([1, 1, 128])
cache_K: torch.Size([1, 13, 128])
cache_V: torch.Size([1, 13, 128])
torch.Size([1, 1, 64])
torch.Size([1])
```

## 7. KV-Cache总结

- KV-Cache 的前身可以追溯到 Transformer 的 Encoder 出来的 KV 值，用于做 cross-attention
- 从 Generate 看出，KV-Cache 存在的必要性，此时能准确计算出 KV-Cache 的显存占用逻辑
- 在 KV-Cache 里优化有4点思路：减少长度，减少头数、减少 bits 数、增加 cache 的管理

## Reference

- 本文摘自[高效Attention]系列：[【手撕LLM-KVCache】显存刺客的前世今生](#)
- LLaMA
- LLaMA2
- MQA
- GQA
- vLLM
- Mistral
- LongLoRA
- Streaming-LLM
- FlashAttention
- LLM-QAT

---

《**手撕RLHF**》解析如何系统的来做LLM对齐工程

小冬瓜AIGC：[【手撕RLHF-Safe RLHF】带着脚镣跳舞的PPO](#)

小冬瓜AIGC：[【手撕RLHF-Rejection Sampling】如何优雅的从SFT过渡到PPO](#)

《**手撕LLM**》系列文章+原创课程：LLM原理涵盖Pretrained/PEFT/RLHF/高性能计算

小冬瓜AIGC：[【手撕LLM-QLoRA】NF4与双量化-源码解析](#)

小冬瓜AIGC：[【手撕LLM-RWKV】重塑RNN 效率完爆Transformer](#)

[小冬瓜AIGC：【手撕LLM-FlashAttention】从softmax说起，保姆级超长文！！](#)

[小冬瓜AIGC：【手撕LLM-Generation】Top-K+重复性惩罚](#)

[小冬瓜AIGC：【手撕LLM-KVCache】显存刺客的前世今生--文末含代码](#)

[小冬瓜AIGC：【手撕LLM-FlashAttention2】只因For循环优化的太美](#)

[《手撕Agent》从代码和工程角度，探索能够通向AGI的Agent方法](#)

[小冬瓜AIGC：【手撕Agent-ReAct】想清楚再行动、减轻LLM幻觉](#)

我是小冬瓜AIGC，原创超长文知识分享，原创课程已帮助多名同学速成上岸LLM赛道：[手撕LLM+RLHF](#)  
研究方向：LLM、RLHF、Safety、Alignment

编辑于 2024-05-23 01:22 · 广东

[LLM](#) [大模型](#) [模型部署](#)

来源：知乎 | 悠趣谷·零成本 | 我要插件